# 集成算法介绍

## Ensemble

吴婷

GitHub: hallo128

# 题纲

- 为什么需要使用集成算法
- 常用的三种集成算法介绍
- 实现集成及效果说明（R语言）
- 结论和使用建议

# 一、为什么需要使用集成算法

- **表现效果：**集成算法表现通常都比单个算法优异，在各种比赛中独占鳌头
- **理论支持：**在PCA框架下，弱可学习与强可学习是等价的。但发现弱学习器通常比发现强学习算法容易得多。

注：

- PCA：probably approximately correct(近似概率正确)

# 二、常用的三种集成算法介绍

Bagging(装袋)、Boosting(提升)、Stacking(堆叠)

**Bagging**：从训练集从进行子抽样组成每个基模型所需要的子训练集，对所有基模型预测的结果进行综合产生最终的预测结果

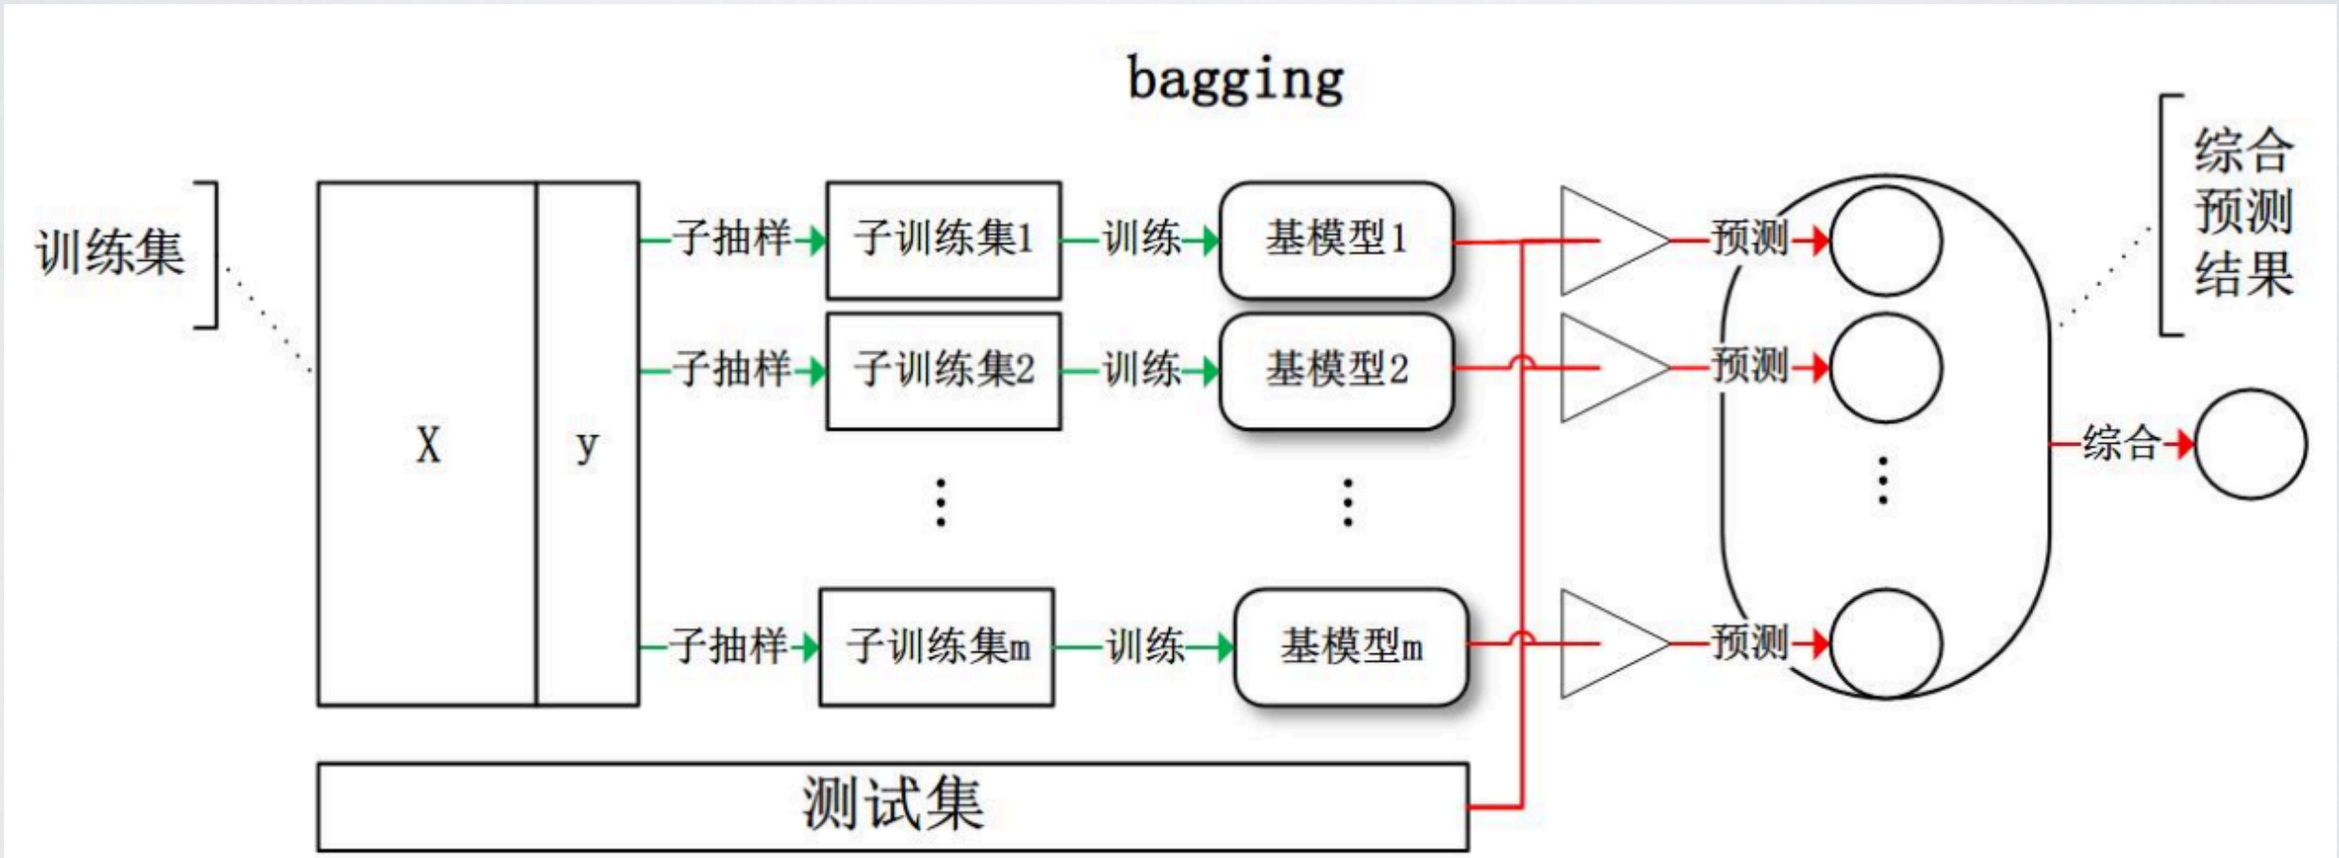

**Boosting**：训练过程为阶梯状，基模型按次序一一进行训练（实现上可以做到并行），基模型的训练集按照某种策略每次都进行一定的转化。对所有基模型预测的结果进行线性综合产生最终的预测结果

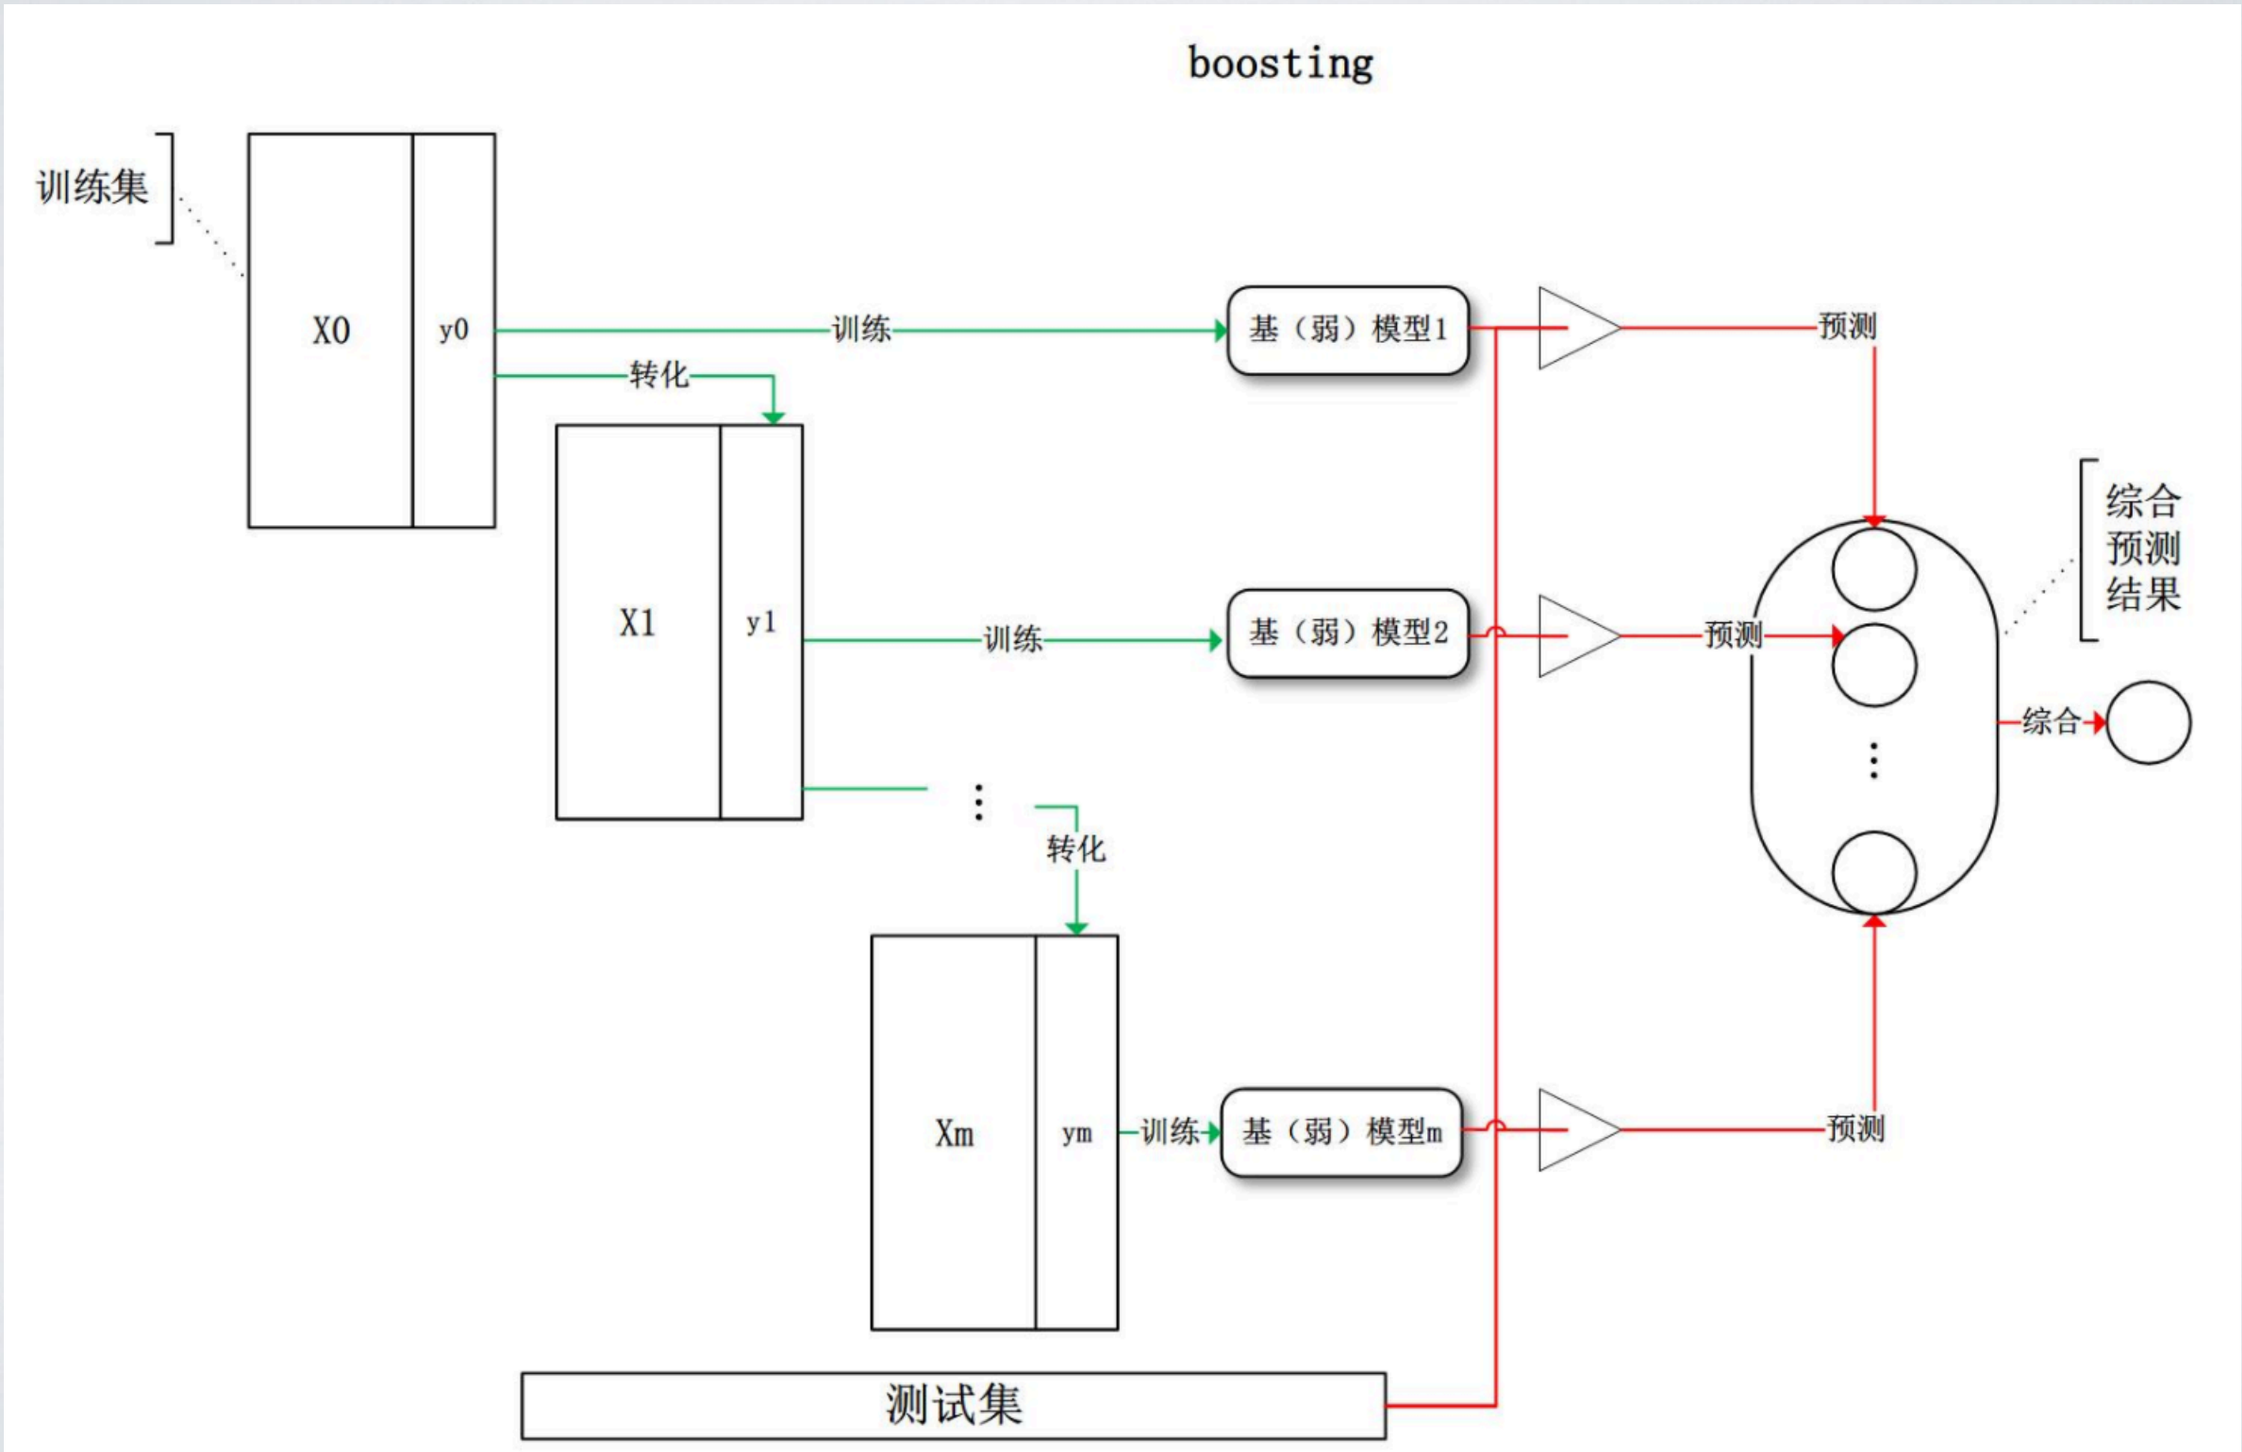

**Stacking**：将训练好的所有基模型对训练基进行预测，第j个基模型对第i个训练样本的预测值将作为新的训练集中第i个样本的第j个特征值，最后基于新的训练集进行训练。同理，预测的过程也要先经过所有基模型的预测形成新的测试集，最后再对测试集进行预测

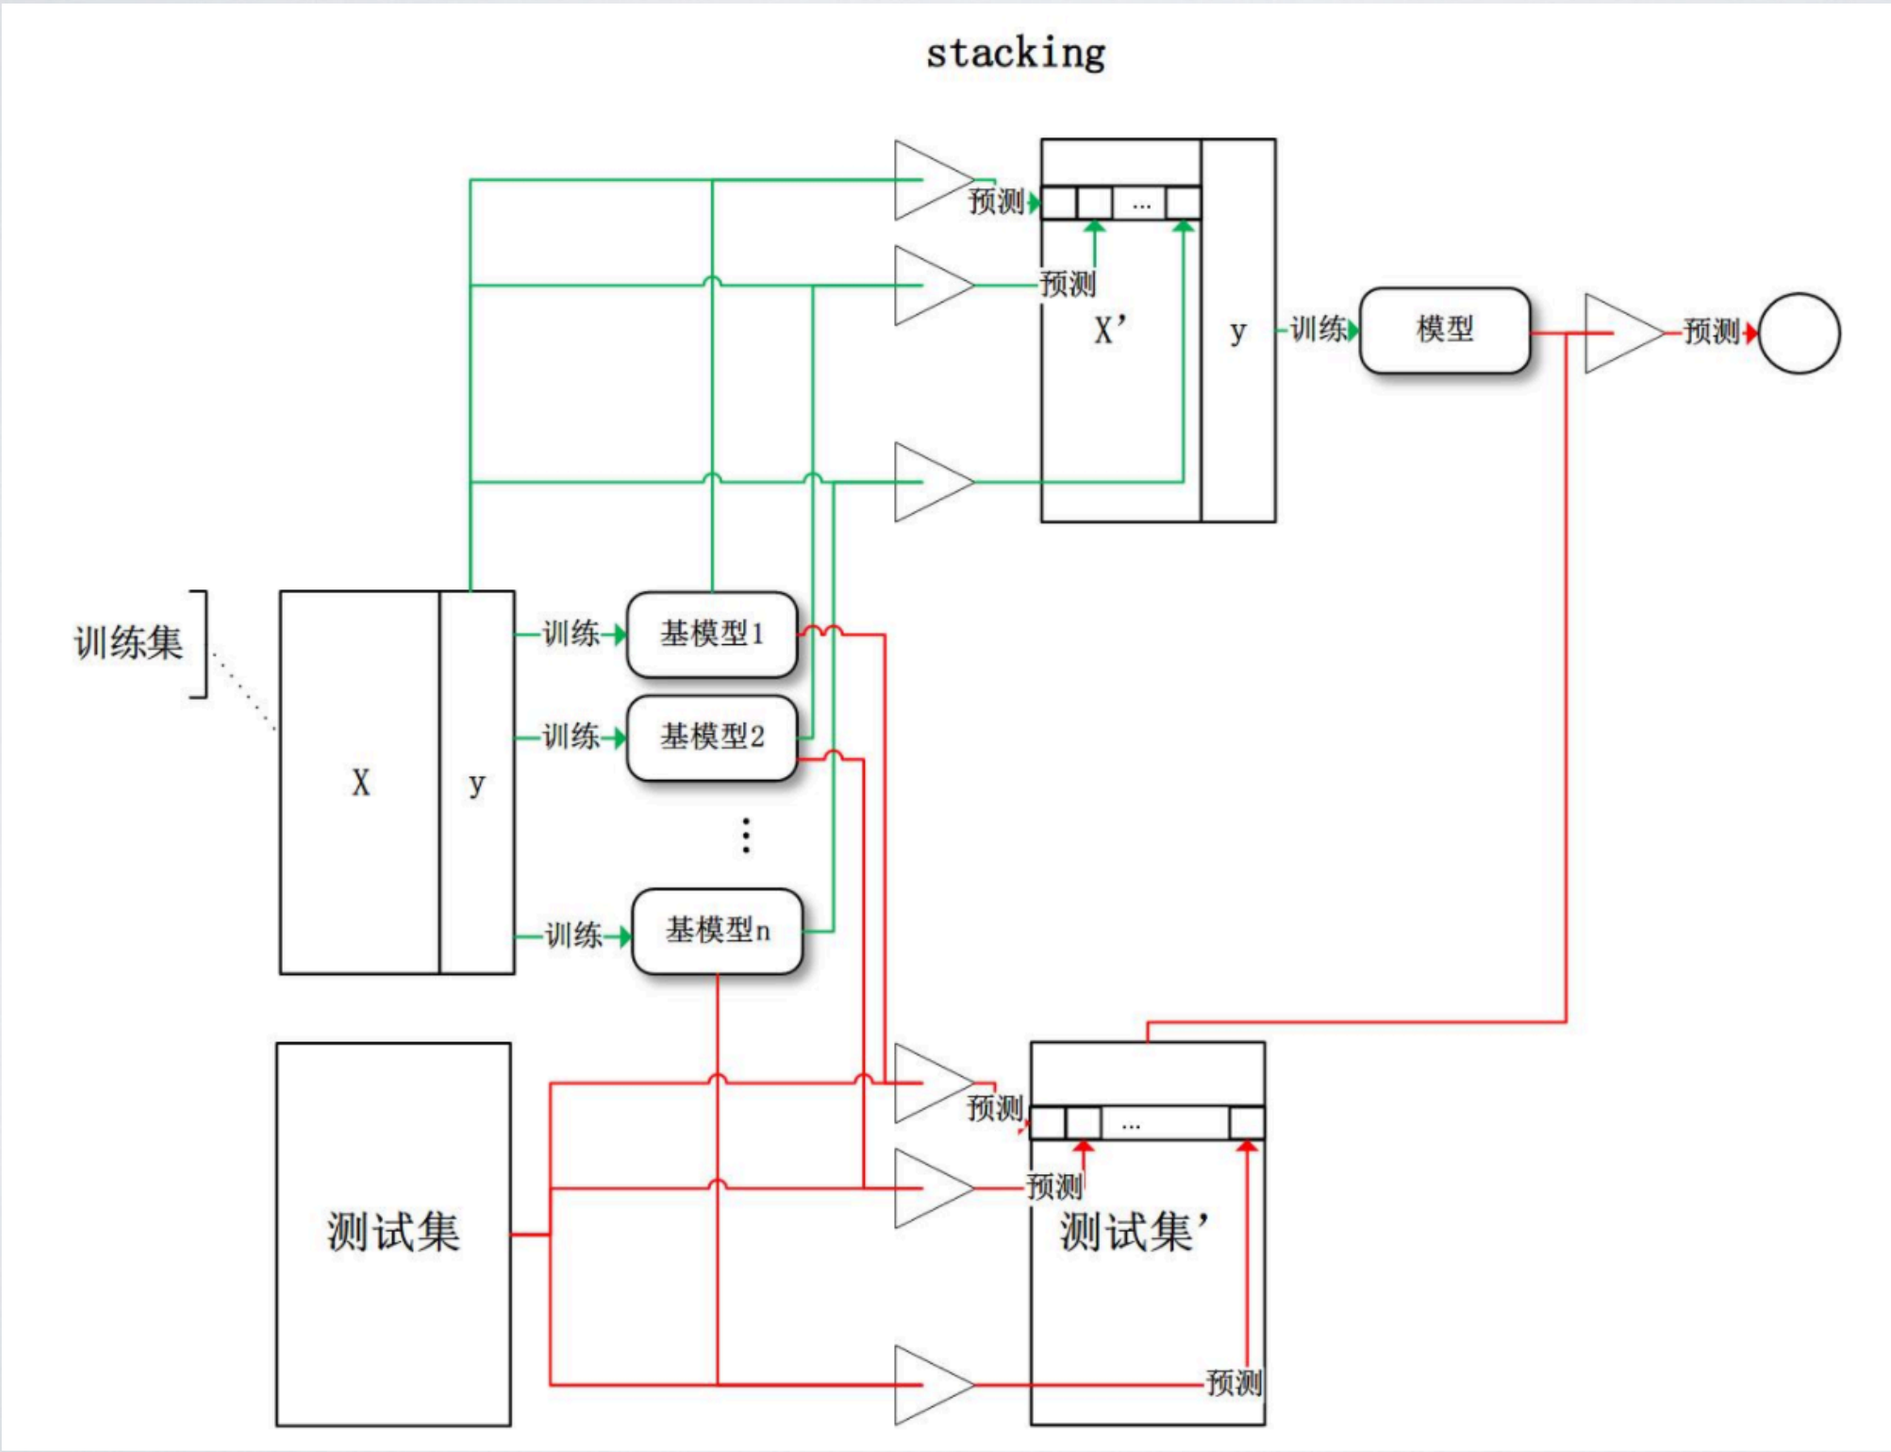

| | Bagging | Boosting |
|---|---|---|
| 基模型特点 | • 强模型(低偏差，高方差)<br>• 模型间**不相关** | • 弱模型(高偏差，低方差)<br>• 顺序生成，相关 |
| 集成目标 | 降低方差 | 降低偏差 |
| 解决思路 | 综合平均降低方差 | 对上一次结果进行修正<br>(如：修正样本判错权重、<br>对上一轮的残差进行拟合) |
| 关键 | • 如何构建有差异性的分类器 | • 权重修正设定<br>• 损失函数的定义 |
| 应用 | **随机森林**是对一般Bagging的<br>改进(行列随机) | GBRT、GBDT、AdaBoost、<br>**GBM、XGBoost** |

# 三、实现集成及效果说明

- 准备工作：在R上安装“mlr”包；打开mlr官网
- 实验流程：先直接使用基本算法+集成算法，查看判别效果；再对集成算法进行调试参数，再比较判别效果
- 运行文件说明：

  mlr_demo3.R：包含了所有尝试过的模型调试内容

  mlr_二分类最优1.R：表现较好的二分类模型，用于集成效果说明

注：

- 具体运行文件所在GitHub：https://github.com/hallo128/MyArticle/tree/master/%E9%9B%86%E6%88%90%E7%AE%97%E6%B3%95
- mlr使用说明：https://mlr-org.github.io/mlr-tutorial/release/html/index.html

# mlr官网—R语言分类算法

## Classification (84)

For classification the following additional learner properties are relevant and shown in column **Props**:

- *prob*: The method can predict probabilities,
- *oneclass*, *twoclass*, *multiclass*: One-class, two-class (binary) or multi-class classification problems be handled,
- *class.weights*: Class weights can be handled.

| Class / Short Name / Name | Packages | Num. | Fac. | Ord. | NAs | Weights | Props | Note |
|---|---|---|---|---|---|---|---|---|
| **classif.ada**<br>*ada*<br><br>ada Boosting | ada<br>rpart | X | X | | | | prob<br>twoclass | `xval` has been set to `0` by default for speed. |
| **classif.adaboostm1**<br>*adaboostm1*<br><br>ada Boosting M1 | RWeka | X | X | | | | prob<br>twoclass<br>multiclass | NAs are directly passed to WEKA with `na.action = na.pass`. |
| **classif.bartMachine**<br>*bartmachine*<br><br>Bayesian Additive Regression Trees | bartMachine | X | X | | X | | prob<br>twoclass | `use_missing_data` has been set to `TRUE` by default to allow missing data support. |
| **classif.binomial**<br>*binomial*<br><br>Binomial Regression | stats | X | X | | | X | prob<br>twoclass | Delegates to `glm` with freely choosable binomial link function via learner parameter `link`. We set 'model' to FALSE by default to save memory. |
| **classif.blackboost**<br>*blackboost*<br><br>Gradient Boosting With Regression Trees | mboost<br>party | X | X | | X | X | prob<br>twoclass | See `?ctree_control` for possible breakage for nominal features with missingness. `family` has been set to `Binomial` by default. For 'family' 'AUC' and 'AdaExp' probabilities cannot be predcited. |

# mlr根据学习任务情况给出的学习器建议

| class | 名称 | package | 只适用于二分类 | 集成算法 |
|---|---|---|---|---|
| classif.binomial | "Binomial Regression" | stats | 1 | |
| classif.blackboost | "Gradient Boosting With Regression Trees" | mboost,party | 1 | boost |
| classif.boosting | "Adabag Boosting" | adabag,rpart | | boost |
| classif.cforest | "Random forest based on conditional inference | party | | bag |
| classif.ctree | "Conditional Inference Trees" | party | | |
| classif.earth | "Flexible Discriminant Analysis" | earth,stats | | |
| classif.featureless | "Featureless classifier" | mlr | | |
| classif.gamboost | "Gradient boosting with smooth components" | mboost | 1 | boost |
| classif.gausspr | "Gaussian Processes" | kernlab | | |
| classif.gbm | "Gradient Boosting Machine" | gbm | | boost |
| classif.glmboost | "Boosting for GLMs" | mboost | 1 | boost |
| classif.kknn | "k-Nearest Neighbor" | kknn | | |
| classif.ksvm | "Support Vector Machines" | kernlab | | |
| classif.lda | "Linear Discriminant Analysis" | MASS | | |
| classif.logreg | "Logistic Regression" | stats | 1 | |
| classif.multinom | "Multinomial Regression" | nnet | | |
| classif.naiveBayes | "Naive Bayes" | e1071 | | |
| classif.nnet | "Neural Network" | nnet | | |
| classif.probit | "Probit Regression" | stats | 1 | |
| classif.qda | "Quadratic Discriminant Analysis" | MASS | | |
| classif.randomForest | "Random Forest" | randomForest | | bag |
| classif.rpart | "Decision Tree" | rpart | | |
| classif.svm | "Support Vector Machines (libsvm)" | e1071 | | |
| classif.xgboost | "eXtreme Gradient Boosting" | xgboost | | boost |

尝试后发现，GBRT和AdaBoost运行调试耗时太长。

最后考虑的集成算法有：GBM、RF、XGBoost

# 三、实现集成及效果说明

- 任务：垃圾邮件的二分类检测任务
- 适用于：自变量X为数值型；输出概率值；平衡样本
- 集成算法：不仅考虑指标表现，还要考虑运行速度

| | task.id | learner.id | logloss.test.mean | auc.test.mean | ssr.test.mean | timetrain.test.mean |
|---|---|---|---|---|---|---|
| 1 | spam | svm | 0.1928965 | 0.9747590 | 0.9426320 | 2.6064 |
| 2 | spam | rpart | 0.3452475 | 0.8897688 | 0.8956389 | 0.0827 |
| 3 | spam | kknn | 0.6444000 | 0.9623043 | 0.9301876 | 0.0003 |
| 4 | spam | nnet | 0.1955470 | 0.9763317 | 0.9439794 | 0.8473 |
| 5 | spam | logreg | 0.2465715 | 0.9710861 | 0.9359583 | 0.3432 |
| 6 | spam | xgboost | 0.5098200 | 0.9333406 | 0.8302262 | 0.0451 |
| 7 | spam | rf | 0.1540522 | 0.9871119 | 0.9595964 | 9.6740 |
| 8 | spam | GBM | 0.6406436 | 0.8797528 | 0.7419429 | 0.4362 |

1. 算法运行速度

从上图的10折交叉验证结果可以看出：

最快的是k近邻算法；速度较慢的是：svm和rf算法。

结论：xgboost确实是集成算法中速度很快的算法。

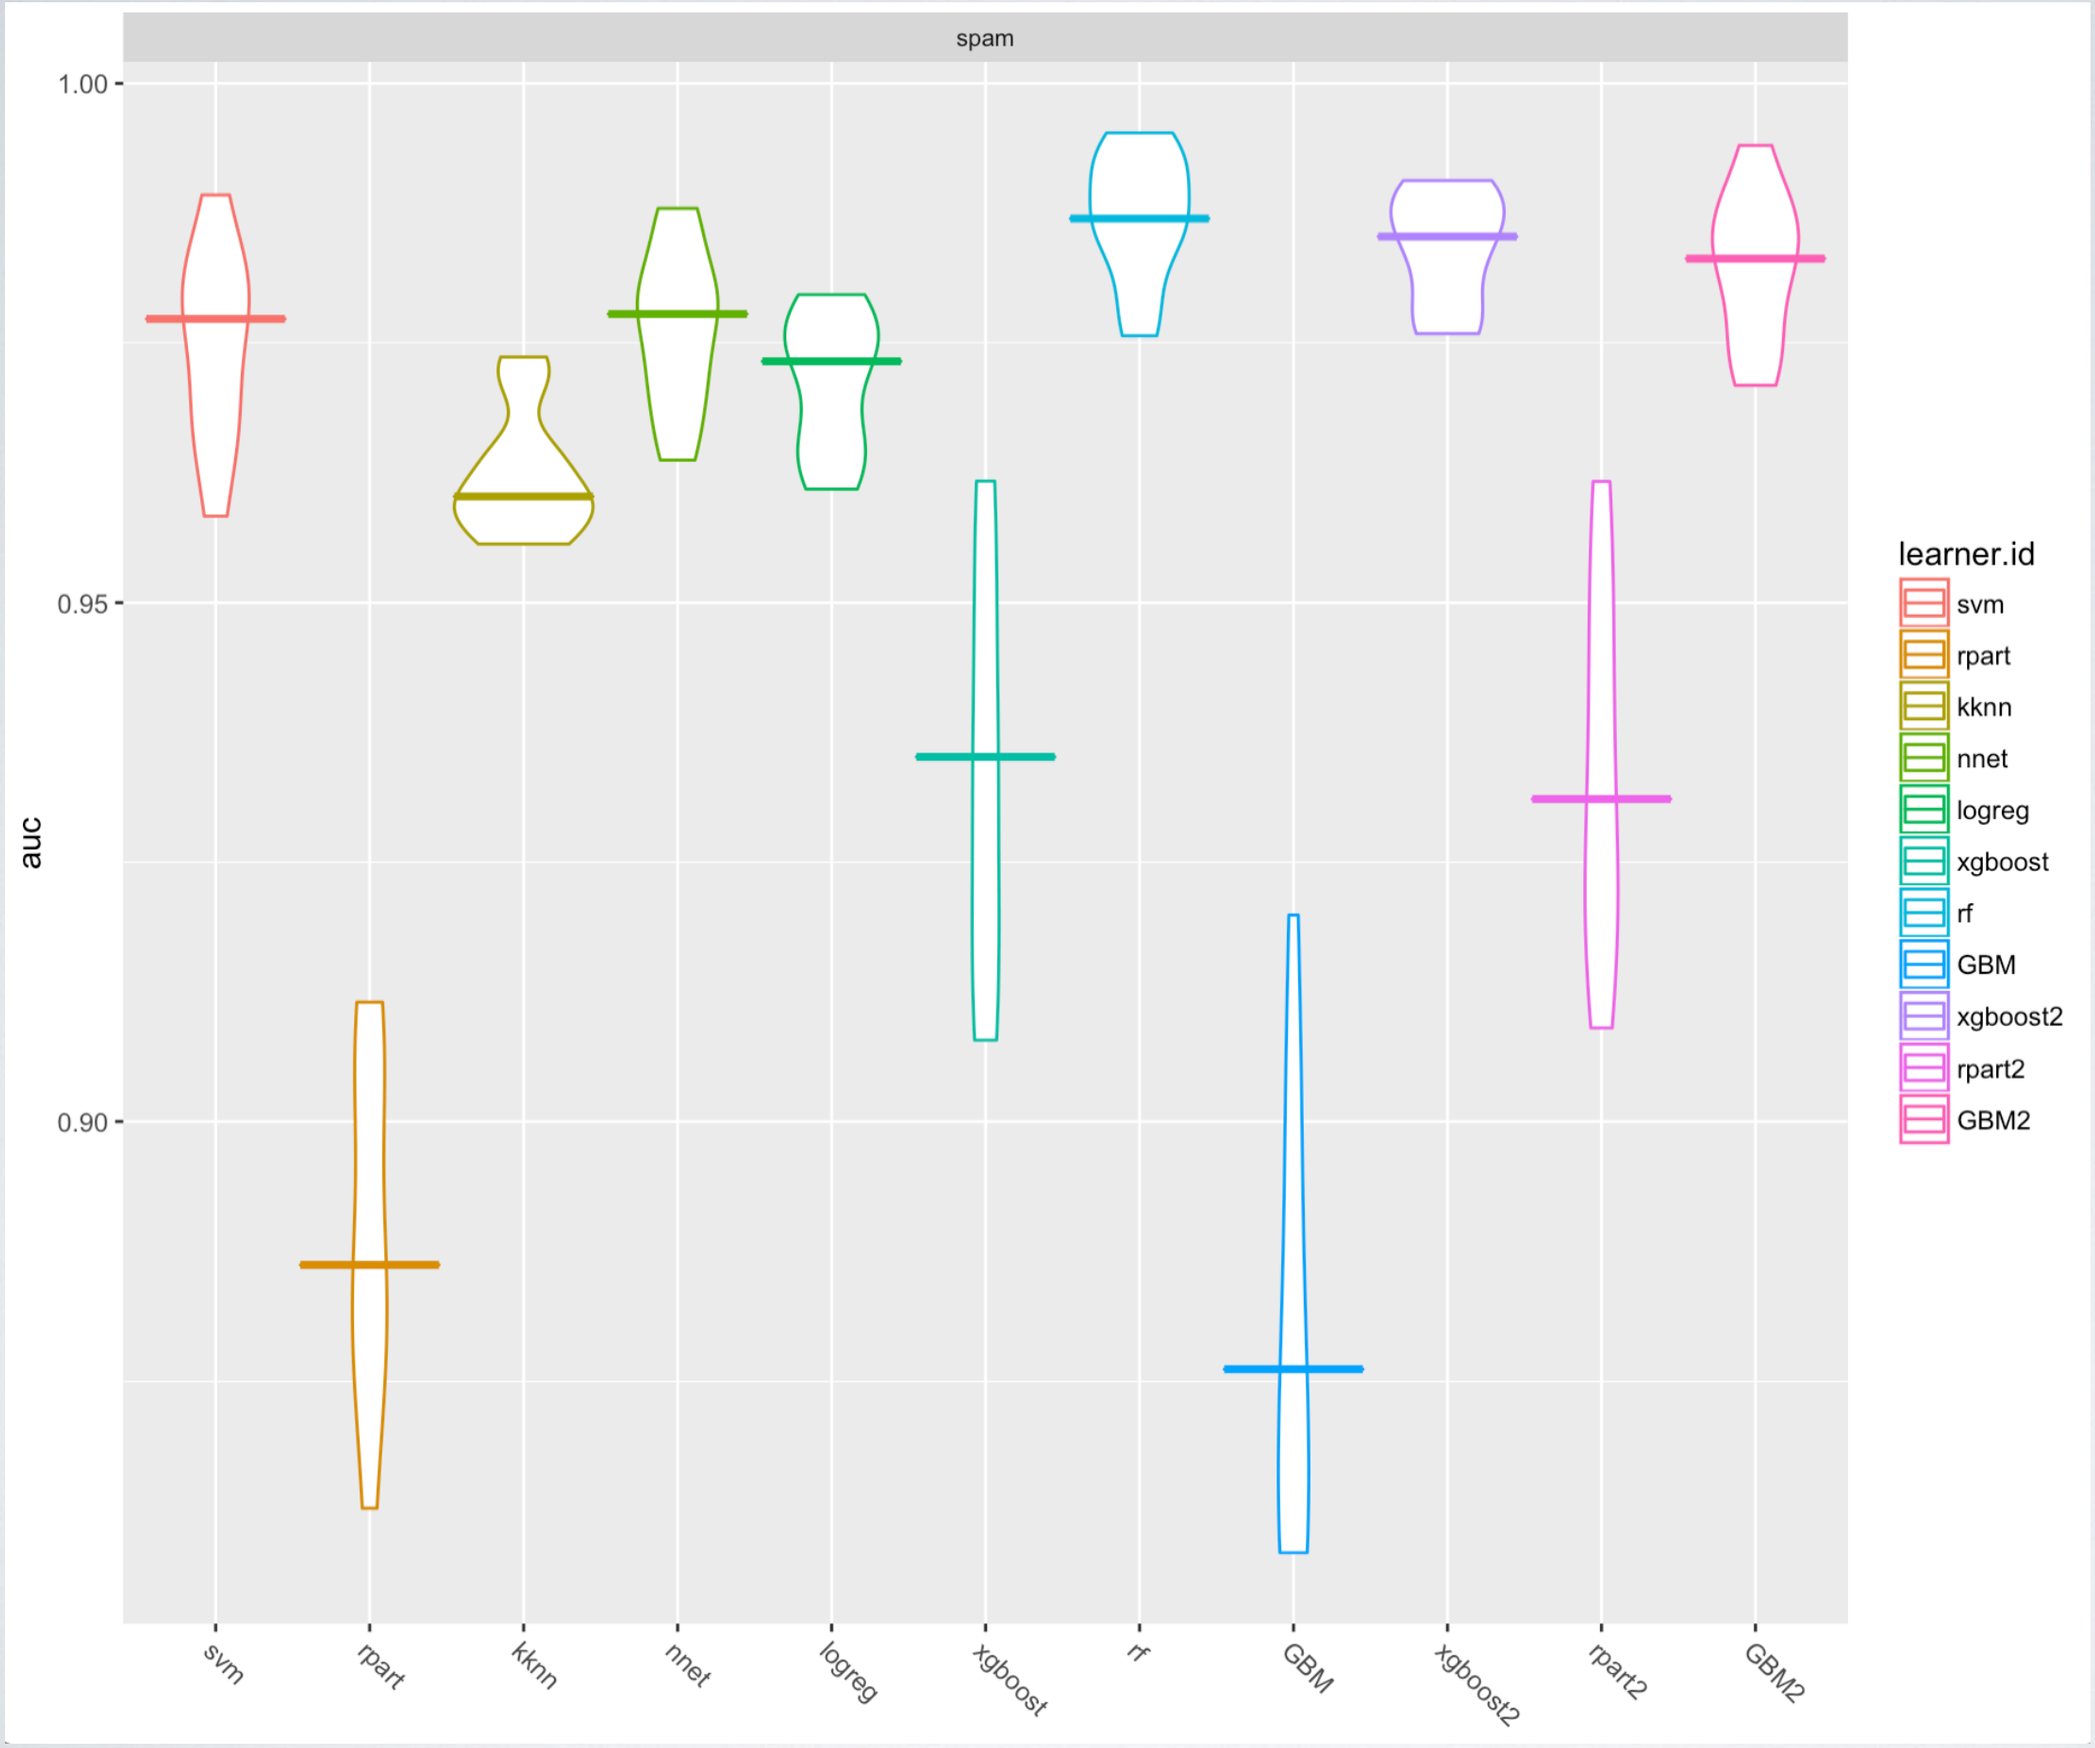


GitHub： hallo128

# XGBoost与GBDT算法的联系与区别

- 都是基于CART、线性分类器，相当于带L1和L2正则化项的逻辑回归(分类)和线性回归(回归)
- 优化时，xgboost对代价函数进行了了二阶泰勒展开，**同时用到了一阶和二阶导**。同时xgboost支持自定义代价函数/优化目标（GBM算法一定程度也可以定义优化目标）
- 在代价函数里加入了**正则项**(如：树的叶子节点个数等)，用于控制模型复杂度。
- **列采样**，借鉴随机森林
- 可以处理缺失
- 支持**并行计算**，近似直方图算法
- 优化目标同时，进行了预剪枝，对节点值进行了平滑

集成算法比较https://www.jianshu.com/p/a69194bdab9e?utm_campaign=maleskine&utm_content=note&utm_medium=seo_notes&utm_source=recommendation

# 四、结论和使用建议

- 集成算法有更大的提升空间，但单个算法几乎很难提升太多
- 使用集成算法大部分时候都需要进行调参，对模型理解要求比较高
- 进行调参时，指定参数及其范围，还有寻优算法，都有很大影响。这也是使用集成算法不得不考虑的事情。
- 同时，目前使用最多的基模型就是树模型，所以要理解集成算法，不得不先掌握有关决策树的理论内容
- Stacking虽然没有重点介绍，但它很有可能为你的模型带来进一步提升。
- 模型融合

二分类算法建议（基于本次实验假定下）：

- 根据速度和结果，建议集成算法选用：GBM(调参)、RF(不调参)、XGBoost(调参)——“mlr包也会给出参数建议”
- 需要调节的参数及范围，如代码所示
- mlr重点在乎效果评判，而各个算法都有自己特别的部分，建议用mlr得到最优算法和参数后，再使用各自算法包，查看更多内容（如：随机森林-各个变量重要性衡量、袋外误差估计OOB error）

# 参考文献


- 李航. 统计学习方法[M]. 清华大学出版社, 2012.
- kaggle第一名的集成思路：https://www.kaggle.com/c/otto-group-product-classification-challenge/discussion/14335
- 集成理论：https://cloud.tencent.com/developer/article/1031762
- 使用sklearn进行集成学习——理论：https://www.cnblogs.com/jasonfreak/p/5657196.html
- 集成算法比较https://www.jianshu.com/p/a69194bdab9e?utm_campaign=maleskine&utm_content=note&utm_medium=seo_notes&utm_source=recommendation

在本次介绍中，并没有具体讲述每个集成算法的理论部分。
虽然集成的思想很简单，但要做到自己从头构建一个大部分时候表现优异，并且能快速运行的集成算法，也是很困难。
个人感觉，在调参数的时候，就已经需要理解大部分的底层实现。所有集成算法可能在一遍调参数，一遍从理论模型上进行调试。更进一步的可能需要去查看源代码是怎么实现的。